# Guia de instalacion Apache Spark

En la siguiente guia aprenderemos como instalar Apache Spark en una maquina con sistema operativo Windows.

### Descarga de Apache Spark

Como primer paso necesitamos bajar la version mas reciente de apache spark

Descargar Spark (http://spark.apache.org/downloads.html)

# Download Apache Spark™

- 1. Choose a Spark release: 3.0.0-preview (Nov 06 2019) ▼
- 2. Choose a package type: Pre-built for Apache Hadoop 2.7
- Download Spark: spark-3.0.0-preview-bin-hadoop2.7.tgz
- Verify this release using the 3.0.0-preview signatures, checksums and project release KEYS.

Note that, Spark is pre-built with Scala 2.11 except version 2.4.2, which is pre-built with Scala 2.12.

Cuando finalize la descarga creamos un folder donde descomprimir nuestro archivo de Spark por ejemplo

C:\Spark

## Descarga de Java 8

Para la ejecucion de Spark como requisito necesitamos una maquina virtual de java corriendo en nuestra computadora por lo que necesitamos instalar Java 8.

Descargar Java 8 (https://www.oracle.com/technetwork/java/javase/jre8-downloads-2133155.html)

Java SE Runtime Environment 8u231  You must accept the Oracle Technology Network License Agreement for Oracle Java SE to download this software.  Accept License Agreement  Decline License Agreement				
Product / File Description	File Size	Download		
Linux x86	67.52 MB	₱jre-8u231-linux-i586.rpm		
Linux x86	83.26 MB	Ţire-8u231-linux-i586.tar.gz		
Linux x64	66.62 MB	Ţre-8u231-linux-x64.rpm		
Linux x64	82.44 MB	Ţre-8u231-linux-x64.tar.gz		
Mac OS X x64	79.91 MB	Fire-8u231-macosx-x64.dmg		
Mac OS X x64	71.46 MB	Fire-8u231-macosx-x64.tar.gz		
Solaris SPARC 64-bit	52.15 MB	Fire-8u231-solaris-sparcv9.tar.gz		
Solaris x64	49.97 MB	Fire-8u231-solaris-x64.tar.gz		
Windows x86 Online	1.97 MB	Fire-8u231-windows-i586-iftw.exe		
Windows x86 Offline	64.93 MB	Ţre-8u231-windows-i586.exe		
Windows x86	67.39 MB	€jre-8u231-windows-i586.tar.gz		
Windows x64	72.8 MB	Ţre-8u231-windows-x64.exe		
Windows x64	72.45 MB	ire-8u231-windows-x64.tar.gz   ire-8u231-windows-x64.tar.gz  ire-8u231-windows-x64.tar.gz		

## **Descargar Winutils**

Para la correcta ejecucion de Spark necesitamos obtener el paquete de Winutils de Hadoop 2.7, esto es necesario para asegurarnos de que spark funcione correctamente en windows, en el siguiente link se explica el por que la necesidad de este paquete <u>Windows problems</u> (<a href="https://cwiki.apache.org/confluence/display/HADOOP2/WindowsProblems">https://cwiki.apache.org/confluence/display/HADOOP2/WindowsProblems</a>)

Ocupamos descargar el repositorio de Aqui (https://github.com/steveloughran/winutils)

y luego copiamos la carpeta de nuestra version a una ruta conocida por ejemplo "C:\Hadoop-2.7.1"

Name	Date modified	Туре	Size
hadoop-2.6.0	8/1/2019 5:54 AM	File folder	
hadoop-2.6.3	8/1/2019 5:54 AM	File folder	
hadoop-2.6.4	8/1/2019 5:54 AM	File folder	
hadoop-2.7.1	8/1/2019 5:54 AM	File folder	
hadoop-2.8.0-RC3	8/1/2019 5:54 AM	File folder	
hadoop-2.8.1	8/1/2019 5:54 AM	File folder	
hadoop-2.8.3	8/1/2019 5:54 AM	File folder	
hadoop-3.0.0	8/1/2019 5:54 AM	File folder	
gitattributes	8/1/2019 5:54 AM	Text Document	1 KB
gitignore	8/1/2019 5:54 AM	Text Document	0 KB
☐ KEYS	8/1/2019 5:54 AM	File	26 KB
LICENSE	8/1/2019 5:54 AM	File	12 KB
README.md	8/1/2019 5:54 AM	MD File	7 KB

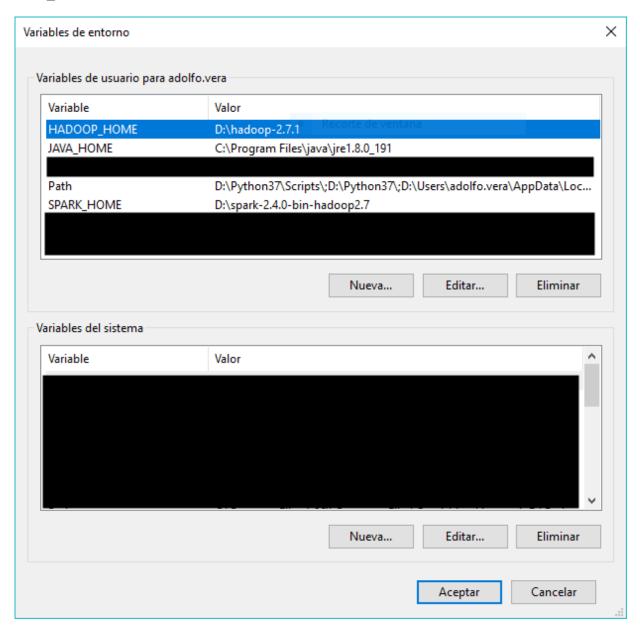
-----

En concreto vamos a crear tres variables de entorno...

SPARK HOME. Ruta al directorio donde hemos descomprimido el paquete de Apache Spark.

HADOOP\_HOME. Apunta al directorio donde hemos copiado la carpeta con la Winutils.

JAVA\_HOME. Es el directorio donde se ha instalado el JRE de Java 8



# Iniciando Apache Spark

Todo lo que necesitamos para arrancar nuestra instalación de Apache Spark se encuentra dentro de la carpeta bin de Apache Spark.

Ahora en una terminal nos dirigimos al folder donde tenemos nuestro Spark instalado y ejecutamos el siguiente comando

spark-class org.apache.spark.deploy.master.Master

```
Sing Spark's default log4j profile: org/apache/spark/log4j-defaults.properties

Jsing Spark's default log4j profile: org/apache/spark/log4j-defaults.properties

Jsing Spark's default log4j profile: org/apache/spark/log4j-defaults.properties

J9/11/24 14:54:18 INFO Master: Started daemon with process name: 141840ESKIOP-8TUDRNH

19/11/24 14:54:20 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable

19/11/24 14:54:20 INFO SecurityManager: Changing wiew acls to: Percy

19/11/24 14:54:20 INFO SecurityManager: Changing modify acls to: Percy

19/11/24 14:54:20 INFO SecurityManager: Changing wiew acls groups to:

19/11/24 14:54:20 INFO SecurityManager: Changing modify acls groups to:

19/11/24 14:54:20 INFO SecurityManager: Changing modify acls groups to:

19/11/24 14:54:20 INFO SecurityManager: SecurityManager: authentication disabled; ui acls disabled; users with view permissions: Set(Percy); groups 19/11/24 14:54:23 INFO Utils: Successfully started service 'sparkMaster' on port 7077.

19/11/24 14:54:23 INFO Master: Starting Spark master at soark://192.168.2.24:7077

19/11/24 14:54:23 INFO Waster: Running Spark version 3.0.0-preview

19/11/24 14:54:23 INFO Waster: Running Spark version 3.0.0-preview

19/11/24 14:54:23 INFO Waster: Bound MasterWebUI to 0.0.0.0, and started at http://DESKTOP-8TUDRNH:8080

19/11/24 14:54:24 INFO Master: Registering worker 192.168.2.24:50398 with 8 cores, 14.9 GiB RAM
```

ahora lo que nos interesa es esta URL donde nuestro master de spark esta corriendo, lo necesitamos para iniciar un **worker** nuestro cluester de Spark con el siguiente comando

#### spark-class org.apache.spark.deploy.worker.Worker spark://192.168.2.24:7077

```
S C:\Spark\spark-3.0.0-preview-bin-haddop2.7\bin> spark-class org.apache.spark.deploy.worker.Worker spark://192.168.2.24:7077

Jsing Spark's default log4j profile: org/apache/spark/log4j-defaults.properties

9/11/24 15:02:22 INFO Worker: Started daemon with process name: 8420@DESKTOP-8TUDRNH

9/11/24 15:02:22 WARN NativeCodeLoader: Unable to load native-haddop library for your platform... using builtin-java classes where applicable

9/11/24 15:02:23 INFO SecurityManager: Changing yiew acls to: Percy

9/11/24 15:02:23 INFO SecurityManager: Changing modify acls to: Percy

9/11/24 15:02:23 INFO SecurityManager: Changing modify acls groups to:

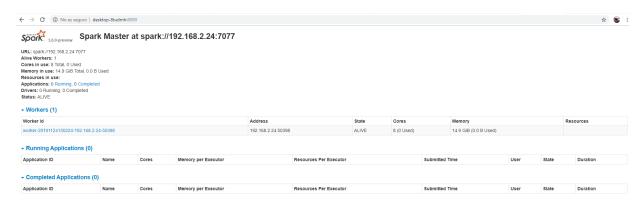
9/11/24 15:02:23 INFO SecurityManager: Changing modify acls groups to:

9/11/24 15:02:23 INFO SecurityManager: Changing modify acls groups to:

9/11/24 15:02:23 INFO SecurityManager: Changing modify acls groups to:

9/11/24 15:02:23 INFO SecurityManager: SecurityManager: authentication disabled; ui acls disabled; users with view permissions: Set(Percy); groupside structure of the security of the securi
```

Accesando la direccion <a href="http://desktop-8tudrnh:8080/">http://desktop-8tudrnh:8080/</a> (http://desktop-8tudrnh:8080/) podremos ver el UI de nuestro cluster de Spark



# Instalar FindSpark

Como parte del ambiente que necesitamos preparar para el estudio de Spark necesitamos instalar el siguiente paquete que utilizaremos en nuestros notebooks.

Abriremos una terminal de nuestro ambiente virtual en Anaconda y ejecutaremos lo siguiente.

#### conda install -c conda-forge findspark

## **Instalar PySpark**

Para nuestro ambiente de desarrollo y analizis tambien necesitamos del paquete PySpark, el cual instalamos con el siguiente comando.

#### conda install -c conda-forge pyspark

#### **Prueba**

Para comprobar que la instalacion fue correcta por favor ejecutar las dos celdas de codigo siguientes que utilizan y levantan un ambiente de trabajo con los paquetes antes instalados.

Si no tenemos errores el proceso de instalación fue satisfactorio.

In [8]:	<pre>import findspark findspark.init("C:\Spark\spark-3.0.0-preview-bin-hadoop2.7")</pre>
	<pre>from datetime import datetime from pyspark.sql import SparkSession from pyspark.sql.functions import col, date_format, udf from pyspark.sql.types import DateType</pre>
In [9]:	
In [10]:	
In [ ]:	
In [ ]:	